

# Titolo

## Multi-Method Rule Extraction from Deep Learning for Interpretable Diabetic Retinopathy Grading

### Fasi Progettazione

#### Overview delle Fasi

| Fase   | Nome                    | Obiettivo                                          | Output Principale                                          |
|--------|-------------------------|----------------------------------------------------|------------------------------------------------------------|
| Fase 1 | Teacher CNN Training    | Training modello deep learning ad alte prestazioni | EfficientNet-B5 con accuracy $\geq 90\%$                   |
| Fase 2 | Explainability Analysis | Analisi e validazione delle predizioni CNN         | Grad-CAM++ maps, IoU $\geq 0.5$ (DDR: 757 img), Prototypes |
| Fase 3 | Rule Extraction         | Distillazione conoscenza in regole interpretabili  | 3 set di regole (DT, LIME, Activation)                     |
| Fase 4 | Sistema Ibrido          | Integrazione CNN + regole in modalità diverse      | 3 modalità operative (post-hoc, rule-guided, ensemble)     |

#### Fase 1 - Teacher CNN Training

| Componente         | Specifica                                    | Dettaglio                                                           |
|--------------------|----------------------------------------------|---------------------------------------------------------------------|
| Architettura       | EfficientNet-B5                              | 30M parametri                                                       |
| Task               | Multi-class classification                   | 5 classi DR                                                         |
| Classi             | No DR, Mild, Moderate, Severe, Proliferative | Progressione severità DR                                            |
| Loss Function      | Focal Loss + Label Smoothing                 | Focal Loss per class imbalance<br>Label Smoothing: $\epsilon = 0.1$ |
| Dataset            | APTOS + Kaggle EyePACS merged                | ~38,788 images totali                                               |
| Tecniche           | Data augmentation, Early stopping            | -                                                                   |
| Target Performance | Accuracy                                     | $\geq 90\%$ su validation set                                       |

#### Fase 2 - Explainability Analysis

| Componente    | Tecnica    | Descrizione                                                                                                                   | Metrica/Output                    |
|---------------|------------|-------------------------------------------------------------------------------------------------------------------------------|-----------------------------------|
| Saliency Maps | Grad-CAM++ | Weighted combination of activation maps da ultimo conv layer<br>Higher resolution vs Grad-CAM standard<br>Better localization | Saliency maps per ogni predizione |

| Componente               | Tecnica    | Descrizione                                                                                                             | Metrica/Output                        |
|--------------------------|------------|-------------------------------------------------------------------------------------------------------------------------|---------------------------------------|
| Validazione Quantitativa | IoU su DDR | Confronto tra Grad-CAM regions e ground-truth lesions<br><b>Dataset:</b> DDR (757 immagini con pixel-level annotations) | <b>Target:</b> IoU $\geq$ 0.5         |
| Clustering               | K-means    | Clustering su activation patterns (layer pre-final)                                                                     | Identificazione prototypes di lesioni |

Fase 3 - Rule Extraction (3 Metodi Comparati)

| Metodo                         | Tipo Output                          | Pipeline Principale                                                                                               | Metrica                                                                                     | Target                                     |
|--------------------------------|--------------------------------------|-------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|--------------------------------------------|
| A - Decision Tree Distillation | Interpretable tree con if-then rules | 1. Synthetic dataset (100k img)<br>2. Training DT (max_depth=20)<br>3. Post-pruning (min_samples_leaf=50)         | <b>Fidelity</b> = Accuracy(DT vs CNN)                                                       | $\geq$ 85%                                 |
| B - LIME-based Rule Induction  | Unordered rule set                   | 1. LIME superpixel importance<br>2. Discretizzazione {Low, Medium, High}<br>3. CN2 Algorithm<br>4. Rule induction | <b>Coverage</b> = % samples con $\geq$ 1 regola                                             | $\geq$ 90%                                 |
| C - Activation Pattern Rules   | Ordered rule list                    | 1. Activation maps (7×7×2048)<br>2. Global Average Pooling<br>3. Top-k channels (k=100)<br>4. RIPPER Algorithm    | <b>Fidelity</b> = Accuracy(Rules vs CNN)<br><b>Coverage</b> = % samples con $\geq$ 1 regola | Fidelity $\geq$ 85%<br>Coverage $\geq$ 90% |

Dettaglio Metodo A - Decision Tree Distillation

1. **Generazione synthetic dataset**
  - Predictions CNN su 100,000 images (training + augmented)
2. **Training Decision Tree profondo**
  - Input: (image features, CNN\_predictions)
  - Parametri: max\_depth = 20
3. **Post-pruning**
  - Minimum samples per leaf = 50
4. **Output:** Interpretable tree con if-then rules

Dettaglio Metodo B - LIME-based Rule Induction

- 1. **LIME**
  - Identificare superpixel importance per ciascuna predizione
- 2. **Discretizzazione**
  - Importance scores → {Low, Medium, High}
- 3. **CN2 Algorithm**
  - Rule induction su discretized explanations
- 4. **Output:** Unordered rule set

**Dettaglio Metodo C - Activation Pattern Rules**

- 1. **Estrazione activation maps**
  - Da ultimo conv layer
  - Shape: 7×7×2048 per EfficientNet-B5
- 2. **Global Average Pooling**
  - Output: 2048-dim vector per image
- 3. **Discretizzazione**
  - Top-k activated channels (k = 100) → binary features
- 4. **RIPPER Algorithm**
  - Rule induction
- 5. **Output:** Ordered rule list

**Nota:** I parametri specifici e le tecniche utilizzate potrebbero variare durante lo sviluppo del progetto in base ai risultati sperimentali e alle esigenze di ottimizzazione.

Fase 4 - Sistema Ibrido

| Modalità   | Strategia              | Descrizione                                                         |
|------------|------------------------|---------------------------------------------------------------------|
| Modalità 1 | Post-hoc Explanation   | CNN prediction con post-hoc rule explanation                        |
| Modalità 2 | Rule-guided Prediction | <b>IF</b> rule confidence > 0.8 → use rule<br><b>ELSE</b> → use CNN |
| Modalità 3 | Ensemble Voting        | CNN + all 3 rule-based predictors                                   |

Dataset

| Fase            | Dataset             | N. Immagini | Utilizzo                                           |
|-----------------|---------------------|-------------|----------------------------------------------------|
| Training CNN    | APTOS 2019          | 3,662       | Training iniziale                                  |
| Training CNN    | Kaggle EyePACS 2015 | 35,126      | Merge per totale ~38,788 images                    |
| Rule Extraction | Synthetic           | 100,000     | Generato da CNN predictions (training + augmented) |
| Testing         | Messidor-2          | 1,744       | External validation                                |

| Fase           | Dataset                  | N. Immagini | Utilizzo                                                                     |
|----------------|--------------------------|-------------|------------------------------------------------------------------------------|
| XAI Validation | DDR (lesion annotations) | 757         | Pixel-level masks + bounding boxes<br>MA (570), HE (601), EX (486), SE (239) |

Metriche di Valutazione

| Categoria       | Metrica            | Target | Descrizione                                                        |
|-----------------|--------------------|--------|--------------------------------------------------------------------|
| CNN Teacher     | Accuracy           | ≥90%   | Performance complessiva                                            |
| CNN Teacher     | Per-class F1-score | -      | Performance per singola classe DR                                  |
| CNN Teacher     | Cohen's Kappa      | -      | Agreement measure                                                  |
| Rule Extraction | Rule Fidelity      | ≥85%   | Agreement tra rules e CNN predictions                              |
| Rule Extraction | Rule Complexity    | ≤5     | Avg conditions per rule (interpretability)                         |
| Rule Extraction | Rule Coverage      | ≥90%   | % test samples con regole attivate                                 |
| XAI Validation  | IoU                | ≥0.5   | Intersection over Union tra Grad-CAM e lesion masks (DDR: 757 img) |